RWB-TECH HACK

Практическое соревнование по ИТ-тематике

МОДЕЛЬ ДАННЫХ CAPIBARA

Хахатоновцы

Кейс «Модель маркетплейса: от корзины до выкупа»

Шалыгин Ярослав · Новак Дмитрий · Клюкин Андрей

РАЗНЫЕ ЦИФРЫ

Исходные данные и правила расчёта

8 исходных файлов
550 759 строк

96 096

покупателей по
customer_unique_id

159.88

средний чек заказа
с доставкой

0

заказов в ноябре 2016
месяц сохранён в отчёте

ПРОВЕРКА ДАННЫХ

Особенности данных и решения в модели

775

заказов без позиций

→ флаг has_items

789

review_id на 2+ заказа

→ составной ключ

610

товаров без категории

→ «без категории»

366

оплата ≠ чек

→ три суммы

189

невозможная хронология

→ флаг + NULL

1 027

индексов без нуля

→ lpad

29

мусорных городов

→ нормализация

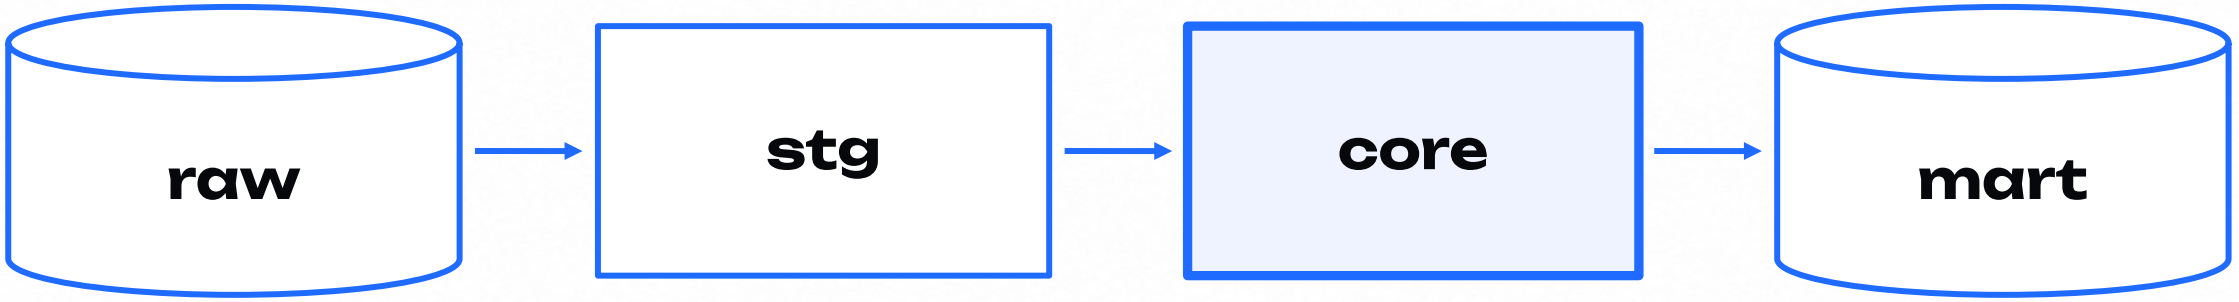
NFD

диакритика в são paulo

→ normalize

ЧЕТЫРЕ СЛОЯ

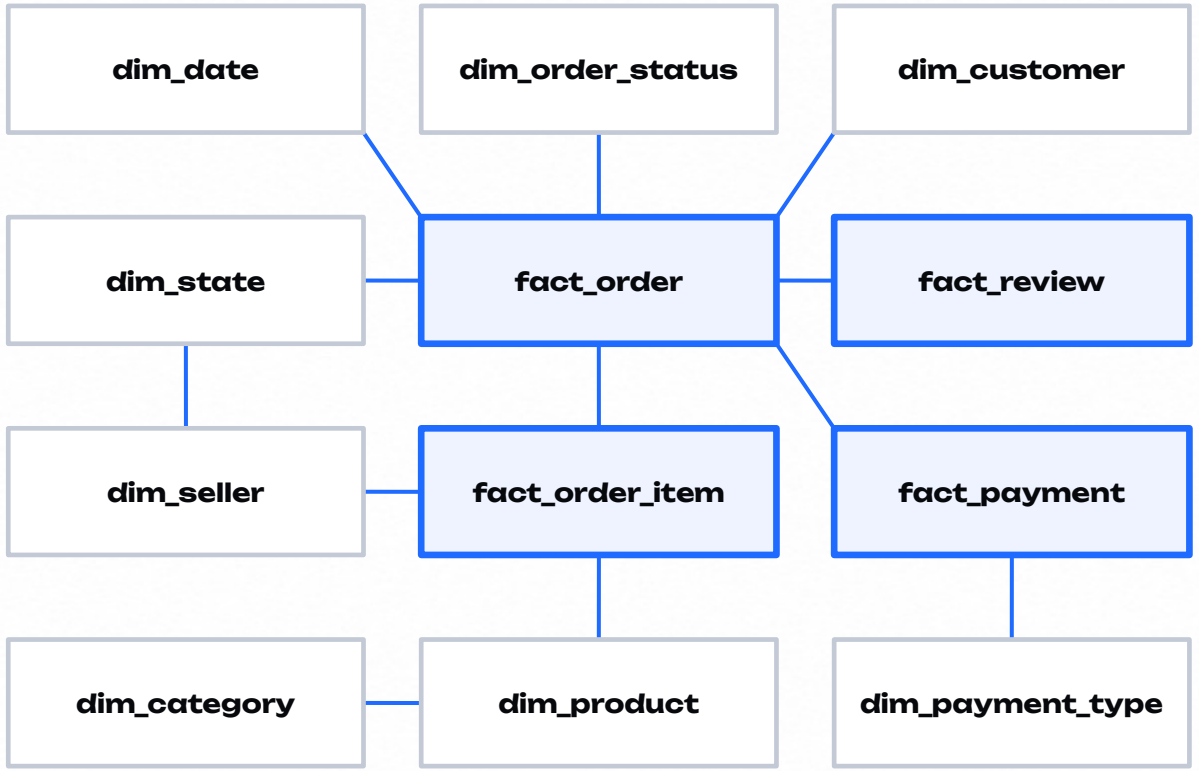
Подготовка данных по слоям



MAKE BUILD одна транзакция · ~30 с · 39 самопроверок

ЗВЕЗДА И ЗЕРНО

Что хранит одна строка каждой таблицы



Факт	Зерно	Ключ
`fact_order`	заказ	`order_id`
`fact_order_item`	единица товара	`order_id, item_id`
`fact_payment`	платёж	`order_id, seq`
`fact_review`	отзыв на заказ	`review_id, order_id`

N×M

позиции и платежи суммируем отдельно, потом соединяем

ОДНО ПРАВИЛО

Правило признания выручки в справочнике статусов

order_status	is_revenue
created	false
approved	false
invoiced	false
processing	false
shipped	false
delivered	✓ **true**
unavailable	false
canceled	false

ЧТО ЕСЛИ

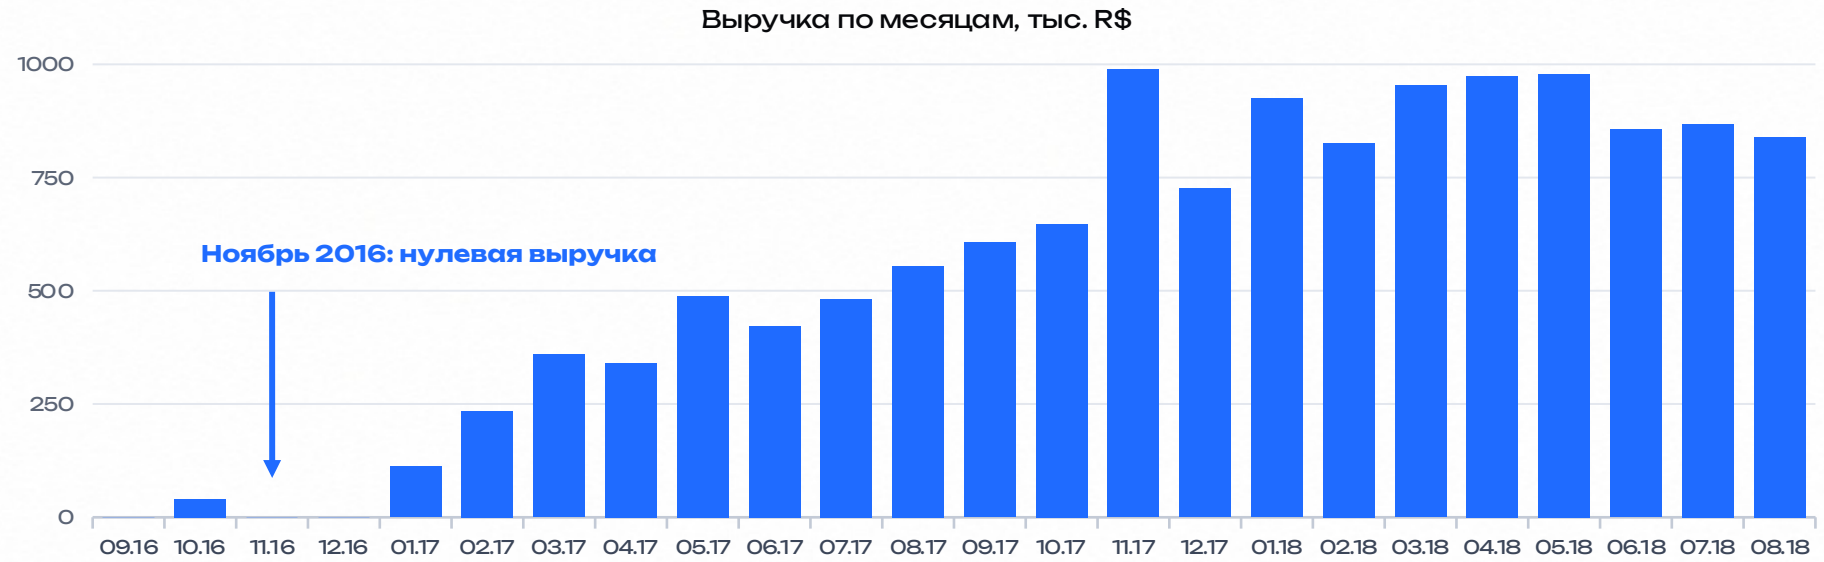
1. выручку признают иначе → **меняем 1 флаг**
2. пришёл новый статус → **dq предупредит**
3. товар без справочника → **уйдёт на −1**

Выручка: товары в статусе delivered

5 из 5

Контрольные цифры совпали
по всем пяти вопросам

Q1	Q2	Q3	Q4	Q5
13 221 498.11	**226 987.93**	**159.88**	**96 096**	**74**
выручка	топ-продавец	средний чек	покупатели · 3.12 %	категорий



САМОПРОВЕРКИ

Проверки количества строк, сумм и связей

```
$ make build

R08  price: raw = core   13 591 643.70  ok
C05  по категориям = общая выручка  ok
M03  медианы совпадают, 27 штатов  ok

39 проверок · 0 ошибок · COMMIT
```

R	11	raw = core
C	6	внутри core
P / I	9	мусор, неизвестное
B / M	13	данные, витрины

Провал критической проверки → откат всей сборки



ОБЕЩАНИЕ ДОСТАВКИ

Средняя оценка при опоздании на 4-7 дней: 2,1

93,2 %	10 дн.	24,4 дн.	11,9 дн.	4,16	985 807
вовремя	медиана	обещаем	запас	оценка	R$ у опоздавших



КТО РЕШАЕТ

Логистика
срок и перевозчик

Продавцы
срок отгрузки

Продукт
оценки и повторы

ЧТО НЕ СКЛАДЫВАЕТСЯ

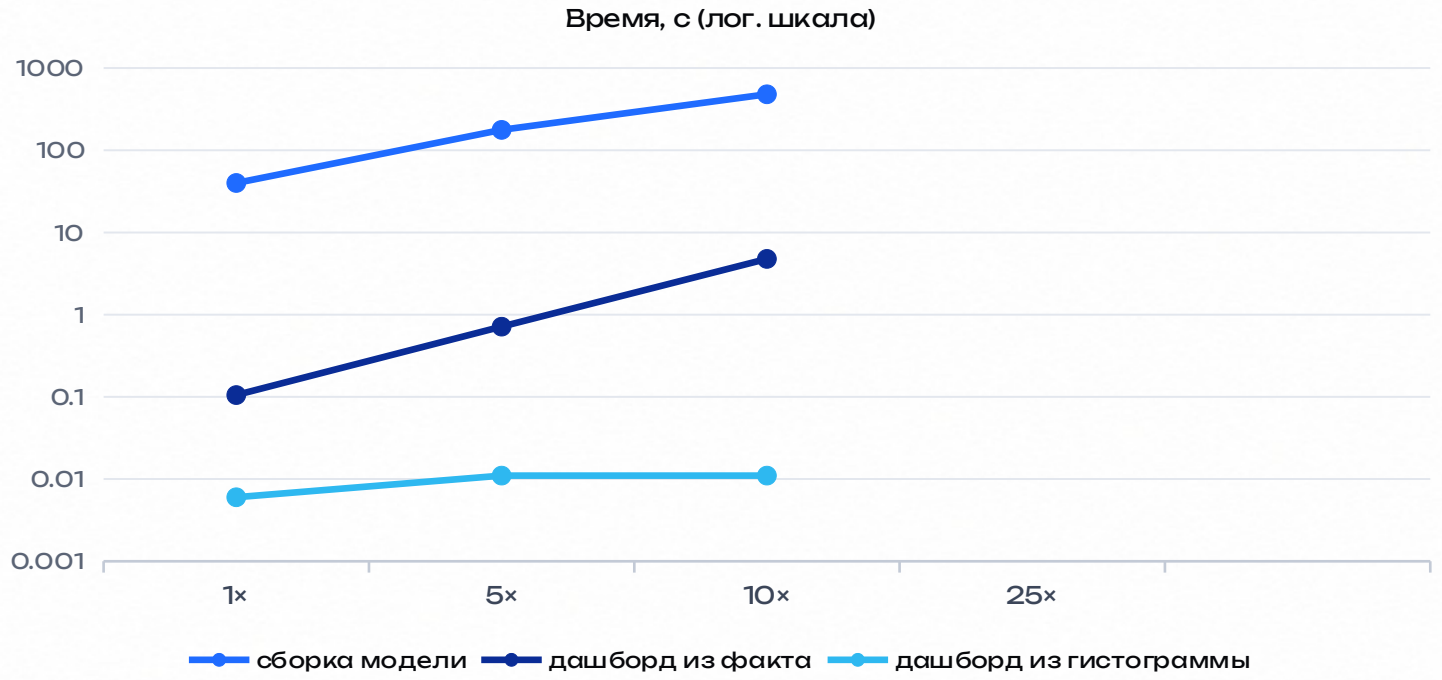
Правила расчёта показателей по группам

Показатель	Почему нельзя	Как храним
Доля, средняя	разный вес срезов	**числитель и знаменатель**
Медиана	медиана медиан ≠ медиане	**гистограмма дней**
Уникальные покупатели	человек в разных месяцах	**пересчёт / HLL**
Опоздание отгрузки	разные сроки продавцов	**по единице товара**

M03 медиана из гистограммы = прямому расчёту по 27 штатам, на каждой сборке

ЗАМЕРЫ

Скорость сборки и запросов
при росте числа заказов



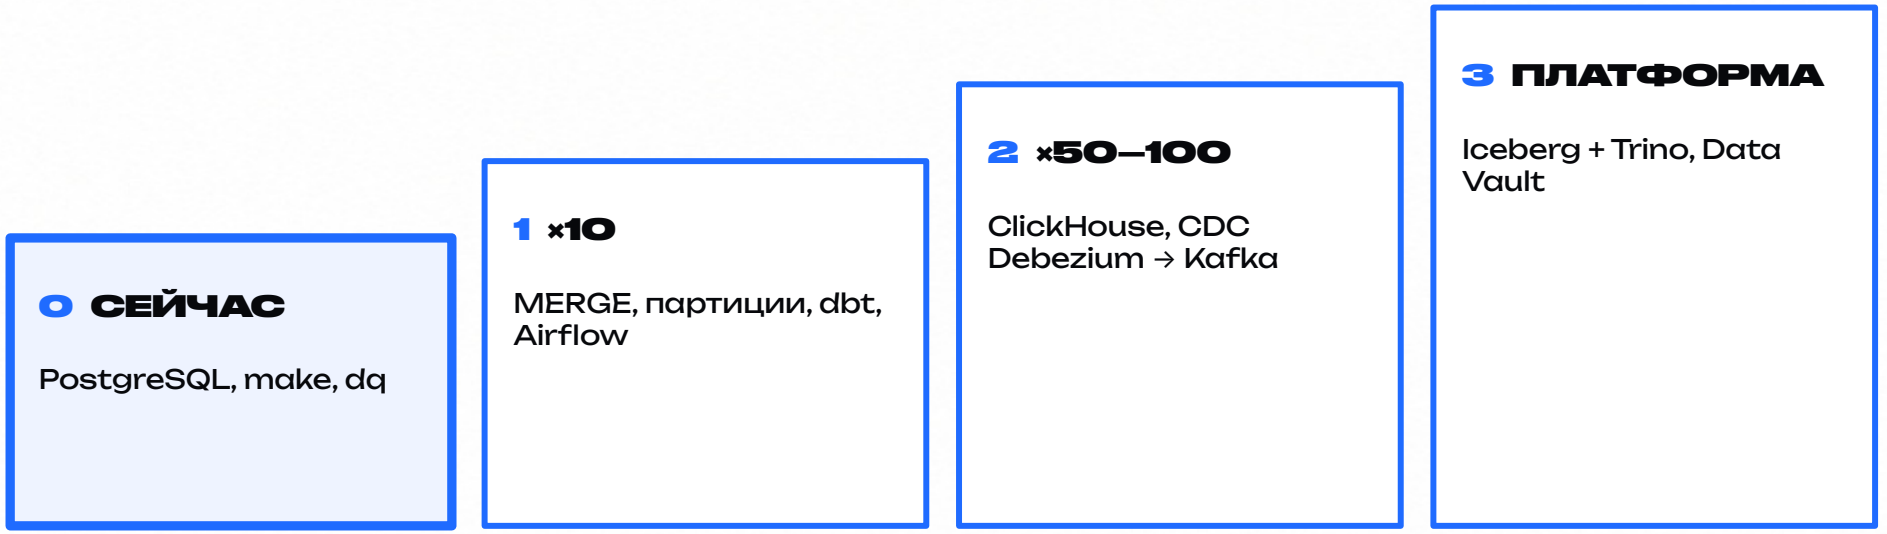
4,8 с
→ 11 мс

тот же запрос на 10×: из факта → из агрегата

1 пересборка → **2** неаддитивность → **3** BI против ETL → **4** ширина снимка

РОСТ ПО ЭТАПАМ

Модель при увеличении нагрузки



НОВЫЕ СУЩНОСТИ

корзина → **выкуп** → возвраты → ПВЗ → финансы продавца

РАБОТА С ИИ

ИИ помогал с черновиками. Команда проверяла результат

Разбор кейса — сами

расшифровали экспертов, схема исходных таблиц

Выбор подхода — ИИ → мы

ИИ сравнивал варианты, утверждали и защищаем мы

SQL и скрипты — ИИ → мы

черновик от ИИ, проверка и правки наши

Дашборд и план — ИИ → мы

черновик от ИИ, цифры пересчитаны на нашей модели

КАК ПРОВЕРЯЛИ

1. **Автотест контрольных цифр**
   make answers гоняет ровно сданные запросы; испорченная цифра валит тест
2. **39 проверок модели**
   строки и деньги до копейки на каждой сборке, провал — откат
3. **Ручные выборки**
   города, отзывы на несколько заказов, заказы с разными продавцами

ГДЕ НЕ СОГЛАСИЛИСЬ

ИИ предложил	Мы сделали — и почему
резать у города любой код штата	`sento se` — реальный город в Баие: режем, только если суффикс = штату строки
`timestamptz` для дат	`timestamp` без зоны: иначе ночные заказы уезжают в соседний месяц
опоздание отгрузки — по заказу	по единице товара: у продавцов одного заказа разные сроки
замеры из черновика стратегии	перемерили на своей сборке — цифры были с чужой

СПАСИБО ЗА КЕЙС!

Готовы ответить на вопросы.

Хахатоновцы · Шалыгин Ярослав, Новак Дмитрий, Клюкин Андрей