ТЕКСТ ВЫСТУПЛЕНИЯ

Слайды 1-5. Ориентир по времени: 0:00-1:40

01 Модель данных Capibara

0:00-0:10

Здравствуйте! Мы команда «Хахатоновцы». Представляем модель данных маркетплейса Capibara: от исходных файлов до проверенных отчётов и анализа доставки.

02 Разные цифры

0:10-0:30

Мы получили восемь файлов, всего около 550 тысяч строк. Перед расчётами нужно было определить общие правила: кого считать покупателем, какие заказы включать в выручку и как учитывать месяцы без заказов. Эти правила мы закрепили в модели, чтобы разные отчёты давали согласованные результаты.

03 Проверка данных

0:30-0:55

Сначала проверили исходные данные. Нашли 775 заказов без товаров, 366 расхождений оплаты со стоимостью заказа и 189 случаев с невозможным порядком дат. Такие записи сохраняем и помечаем признаками проблем. Для товаров без категории создали отдельную группу, для отзывов выбрали ключ из номера отзыва и номера заказа. Города и почтовые префиксы привели к единому виду.

04 Четыре слоя

0:55-1:15

Подготовку разделили на четыре этапа. В raw сохраняем данные как пришли. В stg превращаем текст в числа и даты, чистим значения и повторы. В core создаём связанные таблицы. В mart готовим данные под отчёты. Сборка запускается одной командой и включает автоматические проверки.

05 Звезда и зерно

1:15-1:40

В модели четыре таблицы операций и восемь справочников. В операциях хранятся заказы, товары в заказах, платежи и отзывы. В справочниках находятся их описания: покупатели, продавцы, товары и другие значения. Для каждой таблицы определили, что означает одна строка. Например, три одинаковые футболки дают три товарные строки. Платежи суммируем отдельно, чтобы при соединении таблиц деньги не посчитались повторно.

РАСЧЁТЫ И ДАШБОРД

Слайды 6-9. Ориентир по времени: 1:40-3:20

06 Одно правило

1:40-2:00

Выручкой считаем стоимость товаров без доставки в заказах со статусом delivered, то есть «доставлен». Правило хранится в справочнике статусов, а отчёты используют общий признак is_revenue. Новый неизвестный статус принимаем с предупреждением. Если товар отсутствует в справочнике, его продажа получает ссылку «неизвестно» и остаётся видна.

07 Пять из пяти

2:00-2:25

На модели рассчитали все пять вопросов первого блока. Выручка составила около 13,2 миллиона бразильских реалов, средний чек с доставкой - 159,88 реала. Получили 96 тысяч 96 покупателей, доля повторных - 3,12 процента. В отчёте по категориям 74 группы, включая «Без категории». Ноябрь 2016 сохранился с нулём. Контрольные цифры совпали по всем пяти вопросам.

08 Самопроверки

2:25-2:50

При сборке выполняются 39 проверок. Сравниваем количество записей и суммы с источником, проверяем итоги внутри модели и подготовленные данные отчётов. Например, сумма выручки по категориям должна равняться общей выручке. Известные проблемы данных учитываем отдельно. При критической ошибке сборка отменяется целиком, поэтому предыдущая рабочая версия остаётся доступной. Буквы справа обозначают группы проверок.

09 Обещание доставки

2:50-3:20

Для концепции дашборда выбрали доставку. Он нужен логистике, менеджерам продавцов и продуктовой команде: показывает соблюдение обещанных сроков, этапы задержек и связь с оценками. Среди отобранных корректных доставленных заказов 93,2 процента приехали вовремя, медианный срок - десять дней. При опоздании на четыре-семь дней средняя оценка составляет 2,1. Дашборд помогает выбрать штаты и продавцов для дальнейшей проверки.

РОСТ И ЗАВЕРШЕНИЕ

Слайды 10-14. Ориентир по времени: 3:20-5:00

10 Что не складывается

3:20-3:40

Для показателей описали правила расчёта по группам. Проценты и средние нельзя просто складывать: нужны исходные суммы и количество наблюдений. Одного покупателя нельзя повторно учитывать при сложении месяцев. Для медианы сохраняем распределение заказов по дням доставки. Это позволяет пересчитывать показатель на выбранной группе, например по штату.

11 Замеры

3:40-4:05

Скорость проверили на увеличенных копиях данных. При десятикратном объёме расчёт доставки по штатам из подробных записей занимал около 4,8 секунды. Из заранее подготовленных итогов - 11 миллисекунд. Поэтому частые отчёты ускоряем такими таблицами. При дальнейшем росте ограничением становится и полная пересборка модели. Замеры относятся к нашему тестовому стенду и выбранным запросам.

12 Рост по этапам

4:05-4:35

Развитие предлагаем поэтапное. Сначала обновлять только изменившиеся данные и разделить большие таблицы по месяцам. При дальнейшем росте вынести тяжёлые отчёты в ClickHouse и организовать передачу изменений из источников. Затем можно подключать новые источники. В модели предусмотрено развитие в сторону корзины, возвратов, пунктов выдачи и финансов продавца. Для меняющихся адресов, категорий и условий продавца понадобится хранить версии с периодами действия.

13 Работа с ИИ

4:35-4:55

ИИ использовали для черновиков SQL, скриптов и описаний. Результаты проверяли контрольными цифрами, автоматическими сверками и ручными выборками. Спорные предложения перепроверяли. Например, при очистке городов нельзя удалять любое окончание, похожее на код штата: можно повредить настоящее название. Поэтому удаляем его только при совпадении со штатом этой строки.

14 Завершение

4:55-5:00

Спасибо! Готовы показать расчёты и ответить на вопросы по модели.

ГДЕ ЧТО ЛЕЖИТ

Материалы проекта и обозначения на слайдах

Концепция дашборда и стратегия

Концепция дашборда: слайды 9-10, файл 04_dashboard_concept/README.md. В нём аудитория, решения, макет, показатели, формулы, источники и правила расчёта по группам. Запросы: 04_dashboard_concept/dashboard_queries.sql. Подготовка данных: 01_model/40_mart.sql. Это концепция, интерактивный экран не реализован.

Стратегия развития: слайды 11-12, файл 05_strategy/README.md. В нём замеры, ограничения роста, следующие технологии, новые таблицы и история изменений. Числа замеров: 05_strategy/bench/results.csv.

Деньги и группы проверок

R$: обозначение бразильского реала. «Выручка по месяцам, тыс. R$» означает выручку за каждый месяц в тысячах реалов. Значение 250 на оси означает 250 000 реалов.

$ make build: знак $ показывает приглашение командной строки. В этом месте он не обозначает деньги.

R: 11 сверок источника с готовой моделью: не потерялись ли строки и суммы. R08 - восьмая проверка этой группы, сравнение общей суммы price.

C: 6 проверок согласованности внутри модели. C05 проверяет, что выручка по категориям равна общей выручке.

P: 5 проверок разбора значений и удаления повторов. Например, удалось ли превратить текст в дату или число.

I: 4 проверки неизвестных ссылок и новых значений справочников. Вместе P/I дают 9 проверок.

B: 10 проверок известных особенностей данных, например заказов без товаров и перепутанных дат.

M: 3 проверки подготовленных данных отчётов. M03 сравнивает дискретную медиану из распределения с прямым расчётом по штатам. Вместе B/M дают 13 проверок.

13 591 643,70 на слайде проверок: сумма цен товаров по всем статусам. 13 221 498,11 на слайде ответов: выручка только по доставленным заказам. Это разные расчёты.

СЛОВАРЬ ДЛЯ ЗАЩИТЫ

Короткие объяснения технических слов

fact: таблица операций. Например, что купили и за какую сумму.

dim: справочник или описание. Например, покупатели, товары и статусы.

Зерно: что означает одна строка таблицы - заказ, единица товара, платёж или отзыв.

PK: поле или сочетание полей, которое однозначно определяет строку. FK: ссылка на строку другой таблицы.

N×M: при соединении трёх товаров с двумя платежами получается шесть сочетаний. Чтобы суммы не повторялись, сначала считаем итоги отдельно.

NULL: значения нет или его нельзя надёжно рассчитать. Это не ноль.

COMMIT: база сохраняет изменения сборки. Здесь речь не о коммите Git.

Медиана: значение в середине упорядоченного списка. В отличие от среднего, меньше зависит от отдельных очень долгих доставок.

Гистограмма: сколько заказов доставили за каждое количество дней. Позволяет вычислять медиану без чтения всех заказов.

10×: десятикратный объём данных. мс: миллисекунда, одна тысячная секунды. Логарифмическая шкала: одинаковый шаг оси означает увеличение времени в одинаковое число раз.

BI: отчёты и аналитика. ETL: загрузка и подготовка данных. Они могут конкурировать за ресурсы базы.

HLL: способ приблизительно считать количество разных объектов на больших объёмах. В текущих ответах покупатели считаются точно.

MERGE: обновление существующих строк и добавление новых. Партиции: разделение большой таблицы на части, например по месяцам.

dbt: организация SQL-преобразований и тестов. Airflow: запуск задач по расписанию и зависимостям.

CDC: получение изменений источника. Debezium читает изменения, Kafka передаёт их дальше.

Iceberg: формат хранения больших аналитических таблиц. Trino: инструмент запросов к таким данным. Data Vault: подход к объединению источников с сохранением истории. На слайде это будущие этапы, сейчас они не внедрены.